

트랜스포머와 LLM을 활용한 주가 예측의 지속성 함정 (Persistence Trap) 극복 및 시장 효율성 검증

이연준¹
한국의외국인학교

Overcoming the Persistence Trap in Stock Prediction: A Multi-Modal Approach Using Transformers and LLMs

Yeonjun Lee¹
Korea International School, Gyeonggi, Korea

요약 본 연구는 딥러닝 주가 예측 모델이 전일 가격을 단순 추종하는 '지속성 함정(Persistence Trap)'을 극복하기 위해, 트랜스포머(Transformer)와 LLM 기반 뉴스 심리 분석을 결합한 멀티 모달 아키텍처를 제안하였다. 애플(AAPL) 주가를 대상으로 한 실험 결과, 과거 가격만 학습한 Baseline 모델은 49.79%의 정확도를 기록하며 뚜렷한 후행성(Lag)을 보였다. 반면, 뉴스 데이터를 결합한 제안 모델은 50.40%의 정확도를 달성하여 통계적으로 유의미한 성능 차이는 없었으나, 급변 구간에서 예측 시차를 단축하려는 정성적 패턴을 확인하였다. 그레인저 인과관계 검정($p = 0.39$) 결과는 뉴스 정보로도 효율적 시장의 무작위성을 완전히 설명할 수 없음을 시사했다. 결론적으로 본 연구는 고도화된 AI 로도 효율적 시장 가설(EMH)을 넘기 어려움을 실증하는 한편, 뉴스 데이터가 시차 보정의 트리거로 기능할 수 있다는 공학적 가능성을 제시하였다.

Abstract This study proposes a multi-modal architecture combining Transformers and LLM-based sentiment analysis to overcome the 'Persistence Trap,' where deep learning stock prediction models merely mimic the previous day's price. Experimental results on Apple (AAPL) stock data showed that the Baseline model, trained only on historical prices, recorded a directional accuracy of 49.79%, exhibiting distinct lagging behavior. In contrast, the proposed model integrating news data achieved 50.40% accuracy. Although there was no statistically significant performance difference, qualitative analysis confirmed a pattern of reducing prediction lag during volatile periods. The Granger Causality test ($p = 0.39$) results suggested that news information alone cannot fully explain the randomness of an efficient market. Consequently, this study empirically demonstrates the difficulty of surpassing the Efficient Market Hypothesis (EMH) even with advanced AI, while presenting the engineering potential for news data to serve as a trigger for lag correction.

Key Words : 주제어: 트랜스포머(Transformer), 주가 예측(Stock Prediction), 시차(Time Lag), 지속성 함정(Persistence Trap), 효율적 시장 가설(EMH)

I. 서론

1.1 연구 동기

최근 금융 시장은 인간의 직관에 의존하던 전통적인 방식에서 벗어나, 방대한 데이터를 수학적 모델로 분석하여 매매 의사결정을 내리는 알고리즘 트레이딩이 주류를 이루고 있다. 주식 시장의 가격 데이터는 시간의 흐름에 따라 순서대로 기록되는 시계열(Time-series) 데이터로, 이는 인공지능 분야의 시퀀스(Sequence) 데이터와 본질적으로 동일하다. 마치 언어에서 단어의 배열 순서가 문장의 의미를 결정하듯, 주가 또한 과거의 등락 순서와 맥락이 미래의 추세를 형성하는 핵심 정보가 된다.

기존의 시계열 예측 연구는 주로 순환 신경망(RNN)이나 LSTM(Long Short-Term Memory) 모델에 의존해 왔다. 이 모델들은 데이터를 첫 번째 시점부터 순차적으로 처리(Sequential Processing)한다. 그러나 이러한 방식은 데이터의 길이가 길어질수록 계산 효율이 저하되고, 먼 과거의 중요한 정보가 현재 시점까지 전달되지 못하고 희석되는 장기 의존성(Long-term Dependency) 문제를 야기한다. 이는 마치 긴 문단을 읽을 때 서두의 핵심 정보를 후반부에서 망각하는 현상과 유사한 한계이다. 즉, 이러한 구조적 제약은 긴 시간의 흐름 속에 내재된 복잡한 인과관계를 파악해야 하는 금융 시계열 데이터를 정밀하게 분석하는 데 있어 한계를 가지고 있다.

본 연구는 이러한 한계를 근본적으로 해결하기 위해 **어텐션(Attention)** 메커니즘을 사용하는 트랜스포머(Transformer) 아키텍처를 금융 예측에 적용시키고자 한다. 트랜스포머는 순차적인 처리 방식이 아니라 시퀀스 전체를 한 번에 병렬적으로 참조한다. 이는 마치 책의 내용을 처음부터 끝까지 동시에 펼쳐놓고, 현재 필요한 정보가 몇 페이지에 있는 즉각적으로 찾아내어 연결하는 것과 같다. 이러한 특성은 복잡한 변동성을 가진 주가 데이터에서 먼 과거의 패턴과 현재의 가격 변동 사이의 숨겨진 상관관계를 포착하는 데 탁월한 성능을 발휘할 것으로 예측된다.

1.2 문제 제기:

최근 딥러닝 기술의 발전으로 주가 예측에 관한 연구가 사례가 다수 존재한다. 대표적으로 Fischer 와 Krauss(2018)는 S&P 500 구성 종목에 대해 LSTM 네트워크를 적용한 결과, 기존의 머신러닝 방법론(Random Forest, DNN)을 통계적으로 유의미하게 상회하는 높은 예측 성능과 초과 수익률을 달성했다고 보고하였다[1]. 그러나 이러한 정량적 성과를 실제 트레이딩 관점에서 재검토하면, 모델이 미래의 변곡점을 선제적으로 예측하는 것이 아니라 단순히 과거의 데이터를 답습하는 지속성 함정(Persistence Trap)에 빠져 있는 오류가 발견된다.


실제로 높은 정확도를 자랑하는 대다수의 예측 모델들은 시각적으로는 실제 주가 그래프와 거의 일치하는 것처럼 보이나, 이를 확대해보면 예측 그래프가 실제보다 한 시점(Time-step)씩 뒤로 밀려 있는 **시차(Time Lag)** 현상이 관측된다. 이는 모델이 선행적 정보를 학습한 것이 아니라, 어제 발생한 가격 변동을 오늘에야 뒤늦게 반영하는 후행적(Lagging) 추종을 하고 있음을 의미한다. 결과적으로 이러한 모델은 주가가 급변하는 결정적인 순간에 한 박자 늦은 신호를 보냄으로써 실질적인 투자 가치를 상실하게 된다.

경제학적으로 이는 유진 파마(Eugene Fama)의 '**효율적 시장 가설(EMH)**'을 강력하게 방증한다[2]. 즉, 단순히 공개된 과거의 가격 정보(Price Sequence)만으로는 시장의 무작위성을 극복하고 초과 수익을 낼 수 없다는 이론적 장벽이 AI 모델에서도 여실히 드러나는 것이다. 따라서 단순히 과거의 가격 데이터만을 학습하는 접근법으로는 이러한 '시장의 효율성'과 '무작위성'의 장벽을 넘는 데 구조적인 한계가 존재할 수밖에 없다.

이에 본 연구는 단순한 수치적 정확도(Accuracy) 경쟁을 지양한다. 그 대신, 트랜스포머 모델이 이러한 '구조적 시차'를 극복하고 나이브 예측(Baseline)을 통계적으로 유의미하게 상회할 수 있는지, 그리고 뉴스 심리 데이터라는 대체 정보(Alternative Data)가 인과적 예측의 트리거(Trigger)가 될 수 있는지를 **과학적으로 검증한다**.

II. 이론적 배경

2.1 트랜스포머와 어텐션 메커니즘



[그림 1] 순차적 처리(RNN)와 병렬 처리(Transformer)의 구조적 차이


왼쪽의 RNN은 데이터를 순차적으로 처리하여 장기 의존성 문제가 발생하지만, 오른쪽의 트랜스포머는 전체 시퀀스를 동시에 참조(Attention)하여 정보 손실 없이 긴 맥락을 파악한다.

본 연구는 앞서 제기한 순환 신경망(RNN)의 구조적 한계와 시차(Lag) 문제를 해결하기 위해, 트랜스포머(Transformer) 모델의 핵심인 '스케일 닷-프로덕트 어텐션(Scaled Dot-Product Attention)'을 도입한다[3]. 이 메커니즘은 시계열 데이터를 순차적으로 처리하지 않고, 입력된 모든 시점의 데이터를 세 가지 벡터 공간으로 변환하여 연산한다.

2.2 멀티 헤드 어텐션 (Multi-Head Attention)

주식 시장은 다양한 요인이 얹힌 복잡계이므로 단일 어텐션 필터만으로는 특정 패턴(예: 최근 추세)에 과적합될 위험이 있다. 이를 보완하기 위해 본 연구는 멀티 헤드 어텐션(Multi-Head Attention)을 채택한다. 이 구조는 데이터를 여러 하위 공간(Subspaces)으로 나누어 병렬 연산함으로써, 모델이 단기 변동성과 장기 추세 등 서로 다른 시장 역학을 입체적으로 포착하도록 돕는다. 또한, 정보를 분산 처리하는 과정에서 전일 종가를 단순 추종하는 편향을 방지하는 규제(Regularization) 효과를 제공한다. 이는 노이즈가 많은 금융 데이터에서도 예측의 강건성(Robustness)을 확보하는 데 기여한다.

2.3 거대언어모델(LLM) 기반의 심리 분석 (LLM-based Sentiment Analysis)



[그림 2] LLM 기반 뉴스 심리 지수 산출 과정 비정형 텍스트인 뉴스 데이터를 입력받아, LLM(Gemini 2.5 Pro)을 통해 문맥(Context)을 분석한 후 -1.0에서 +1.0 사이의 정량적 심리 지수(Sentiment Score)로 변환하는 도식이다.

효율적 시장 가설에 따르면 현재 주가는 과거 정보를 모두 반영하고 있어, 가격 데이터만 학습할 경우 필연적으로 예측 시차가 발생한다. 이러한 내생적 한계를 극복하기 위해 외생적 정보인 뉴스를 활용하며, 단순 키워드 매칭을 넘어선 거대언어모델(LLM)을 도입하여 시장 심리를 정교하게 포착한다.

LLM 기반 접근 방식의 핵심 우위는 다음과 같다.

- **첫째, 문맥 인지를 통해 정보의 경제적 함의를 정밀하게 추출한다.** 기존의 단어 빈도 분석과 달리, 트랜스포머 기반의 LLM은 문장 전체의 뉘앙스를 파악한다. 예컨대 "순이익이 감소했으나 시장 예상치를 상회했다"는 복합적인 정보를 긍정적 신호로 해석하는 등, 텍스트 이면의 실질적인 시장 충격을 정량화하여 데이터 품질을 개선한다.
- **둘째, 가격 결정의 선행 지표(Leading Indicator)로서 기능한다.** 가격 데이터가 시장 반응 후 남겨진 과거 정보라면, 뉴스는 주주의 매매를 유발하는 실질적 동기 역할을 한다. LLM이 추출한 심리 지수는 모델이 과거 추세를 맹목적으로 추종하는 관성에서 벗어나, 외부 충격에 의한 추세 전환점을 선제적으로 감지하도록 돕는 결정적인 보정 신호로 작용한다.

2.4 그레인저 인과관계 검정 (Granger Causality Test)

본 연구는 딥러닝 모델의 예측 성능을 단순히 오차(MSE)나 정확도(Accuracy)로만 평가하는 관행을 지양한다. 앞서 1.2 절에서 지적하였듯, 시계열 모델은 단순히 전일 데이터를 추종하는 '지속성 함정'에 빠져 있어도 높은 정확도를 보일 수 있기 때문이다. 따라서 본 연구에서는 뉴스 심리 데이터(x)가 주가 변동(y)을 예측하는 데 있어 통계적으로 유의미한 선행 정보(Leading Information)를 제공하는지를 검증하기 위해 그레인저 인과관계 검정(Granger Causality Test)을 도입한다[4].

그레인저 인과관계의 수학적 정의는 다음과 같다. 어떤 시계열 변수 y 를 예측할 때, y 과거 데이터만을 사용하는 경우보다 다른 변수 x 의 과거 데이터를 함께 사용할 때 예측 오차(Prediction Error)가 통계적으로 유의미하게 감소한다면, " x 는 y 의 그레인저 원인(Granger Cause)이다"라고 정의한다.

여기서 귀무가설은 "뉴스 심리 데이터(x)의 모든 계수가 0이다", 즉 "뉴스는 주가 예측에 아무런 도움이 되지 않는다"로 설정된다.

본 연구는 뉴스 데이터가 주가 예측 오차를 통계적으로 유의미하게 줄여주는지 확인하기 위해 그레인저 인과관계 검정을 수행한다. 이는 단순한 상관관계를 넘어, 뉴스가 주가 변동에 실질적인 선행 정보(Leading Information)를 제공하는지 판별하는 엄밀한 검증 도구(Verification Tool)로 활용된다.

III. 연구 설계 및 방법론

3.1 데이터 수집 및 전처리 (Data Collection and Preprocessing)

본 연구는 애플(AAPL)의 2010 년부터 2020 년까지의 주가 및 뉴스 데이터를 활용하였으며, 구체적인 전처리 과정은 다음과 같다.

- 가. **로그 수익률 변환:** 시계열 데이터의 대전제인 정상성(Stationarity) 확보를 위해, 추세가 포함된 수정 증가 대신 로그 수익률(Log Return)을 사용하였다. 이는 주가의 절대적 가격이 아닌 변화율에 집중하게 하여 모델이 단순 우상향 패턴을 학습하는 오류를 방지한다.
- 나. **뉴스 데이터 정량화:** 비정형 텍스트인 뉴스 헤드라인은 'Gemini 2.5 Pro'를 통해 단순 긍/부정을 넘어 경제적 문맥을 반영한 감성 지수(-1.0~+1.0)로 변환하였다. 이후 주가 데이터와의 스케일(Scale) 차이를 보정하고 학습 효율을 높이기 위해 Standard Scaler 를 적용하여 정규화하였다.
- 다. **시퀀스 구성:** 슬라이딩 윈도우(Sliding Window) 방식을 적용, 과거 60 일(약 1 분기)의 데이터를 하나의 입력 시퀀스로 묶어 단기 노이즈와 중기 추세를 동시에 포착하도록 구성하였다.


3.2 모델 아키텍처 및 학습 설정 (Model Architecture and Training Setup)

본 연구에서 구축한 트랜스포머 기반 예측 모델의 세부 아키텍처와 하이퍼파라미터 설정은 다음과 같다.

Model A: Baseline Model (Only End Price)



Model B: Integrated Architecture (End Price + LLM-Generated Sentiment)



[그림 3] 제안된 모델의 전체 아키텍처 개요 (위) Model A 는 과거의 주가 데이터(Log Return)만을 입력으로 사용하는 Baseline 모델이다. (아래) Model B 는 주가 데이터와 LLM(Gemini)이 분석한 뉴스 심리 데이터를 결합하여 멀티 모달(Multi-modal)로 학습하는 제안 모델 구조를 나타낸다

가. 입력 및 인코더 구조 (Input & Encoder)

모델의 입력 차원은 (Batch Size, 60, 2)로, 60 일간의 '로그 수익률'과 '뉴스 감성 지수' 2 가지 변수(Feature)를 포함한다. 핵심인 멀티 헤드 어텐션 층은 4 개의 헤드(num_heads=4)로 구성되어 시장을 다각도로 분석하도록 설계하였으며, 키 벡터의 차원(key_dim)은 256 으로 설정하였다. 또한, 어텐션 연산 직후에는 0.25 의 비율로 드롭아웃(Dropout)을 적용하고 층 정규화(Layer Normalization)를 수행하여 과적합(Overfitting)을 방지하고 학습의 안정성을 확보하였다.

나. 피드 포워드 및 출력층 (Feed-Forward & Output)

인코더를 통과한 벡터는 1D 합성곱(Conv1D) 레이어와 전역 평균 풀링(Global Average Pooling)을 거쳐 정보를 압축한다. 최종적으로 128 개의 유닛을 가진 밀집층(Dense Layer)을 통과한 후, 1 개의 출력 뉴런을 통해 다음 날의 주가 변동률을 예측한다.

다. 학습 전략 (Training Strategy)

모델 학습을 위한 손실 함수(Loss Function)로는 평균 제곱 오차(MSE)를 사용하였으나, 평가 시에는 방향성 정확도(DA)를 주지표로 활용한다. 최적화 알고리즘은 Adam Optimize 를 채택하였으며[6], 학습 과정에서 검증 손실(Validation Loss)이 개선되지 않을 경우 학습을 조기 종료하는 Early Stopping 기법을 적용하여 모델의 최적 성능을 보존하였다

IV. 실험 결과

4.1 정량적 성능 비교

본 연구는 '가격 데이터만 학습한 모델(Baseline)'과 '뉴스 심리 데이터를 결합한 모델(Proposed)'의 성능을 방향성 정확도(Directional Accuracy, DA)를 기준으로 비교 분석하였다. 실험 결과는 [표 1]과 같다.

모델 구분	입력 피쳐	MSE (Scaled)	방향성 정확도 (DA)
Baseline 모델	종가(Close)	0.00057	49.79%
Sentiment 모델	종가 + 뉴스 감성	(유사 수준)	50.40%

[표 1] 모델별 성능 비교 요약 Baseline 모델과 제안 모델(Sentiment)의 입력 피쳐 차이와 이에 따른 MSE(평균 제곱 오차) 및 방향성 정확도(DA) 비교 결과.


- **Baseline 모델:** 시장의 효율성 입증 과거의 가격 정보(Log Returns)만을 학습한 Baseline 모델은 49.79%의 정확도를 기록하였다. 이는 동전 던지기 확률(50%)보다도 낮은 수치이다. 이는 1.2 절에서 제기한 '효율적 시장 가설(EMH)'을 강력하게 뒷받침하는 결과로, 공개된 과거의 가격 패턴만으로는 미래의 주가 등락을 전혀 예측할 수 없음을 실증적으로 보여준다. 즉, 주가는 '랜덤 워크(Random Walk)'에 가까운 움직임을 보였다.
- **Sentiment 모델:** 제안 모델은 50.40%를 기록하여 Baseline(49.79%) 대비 소폭 상승하였다. 이는 통계적으로 유의미한 차이라고 보기는 어려우나, 모델이 단순히 50% 확률에 수렴하는 랜덤

워크(Random Walk) 패턴에서 벗어나려는 초기적인 신호(Initial Signal)를 보였다는 점에서 제한적인 의미를 찾을 수 있다.

4.2 정성적 분석: 시차(Lag)의 극복 (Qualitative Analysis)

단순한 수치 비교를 넘어, 실제 예측 그래프의 형태를 분석하면 두 모델의 구조적인 차이가 드러난다.

가. Baseline 모델의 한계




[그림 4] Baseline 모델의 예측 결과 (AAPL) 예측선(초록 점선)이 실제 주가(파란 실선)보다 약 1 일(1 Time-step) 뒤쳐져서 움직이는 시차(Time Lag) 현상이 뚜렷하게 관측된다. 이는 모델이 미래를 예측한 것이 아니라 전일 종가를 추종하는 '지속성 함정'에 빠져 있음을 보여준다.

위의 [그림 4]는 Baseline 모델의 예측 결과를 주가로 변환한 것이다. 얼핏 보면 예측선(초록 점선)이 실제 주가(파란 실선)를 잘 따라가는 것처럼 보이지만, 급락 구간을 자세히 관찰하면 예측선이 실제보다 **약 1 일(1 Time-step) 뒤쳐져서 움직이는 현상**이 확인된다. 이는 모델이 미래를 예측한 것이 아니라, "내일 주가는 오늘과 같다"는 나이브 예측(Naïve Forecast)을 수행하며 지속성 함정(Persistence Trap)에 빠져 있음을 시각적으로 증명한다.

나. 뉴스 심리 모델의 성능 향상

[그림 5]는 제안 모델이 예측한 로그 수익률(빨간 점선)을 나타낸다. Baseline 모델과 달리, 제안 모델은 뉴스 심리 데이터를 트리거(Trigger)로 삼아 주가의 급등락이 발생하는 구간에서 그 방향(Sign)을 맞춰가려는 패턴을 보인다. 비록 예측의 정확도가 50.40%로 높지는 않았으나, 단순히 전일 데이터를 답습하는 수준을 넘어 외부 충격(뉴스)에 반응하며 시차를 줄이려는 시도를 보였다는 점에서 공학적 의의가 있다.

이를 정량적으로 검증하기 위해 Lag 1 자기상관계수(Autocorrelation at Lag 1)를 분석하였다. 주식 시장에서 '지속성 함정'에 빠진 모델은 어제의 가격이 오늘의 예측값이 되는 경향이 강해, Lag 1에서의 상관계수(r)가 1에 수렴한다.



[그림 5] 제안 모델(Sentiment)의 로그 수익률 예측 결과 (Last 150 Days) 뉴스 데이터를 통해 급격한 변동(Spike)이 발생하는 구간에서 방향성을 탐지하려는 경향을 보인다. 비록 정확도는 낮으나, Baseline 과 달리 외부 충격에 반응하여 시차를 줄이려는 패턴이 확인된다.

분석 결과, Baseline 모델은 $r = 0.9998$ 을 기록하여 전일 가격에 대한 의존도가 절대적임을 수치적으로 증명하였다. 반면, 제안 모델은 $r = 0.1575$ 로 급격히 감소하였다. 이는 모델이 더 이상 과거 가격을 단순 복제하지 않으며, '직렬 의존성(Serial Dependence)'이라는 시계열 딥러닝의 고질적인 구조적 결함을 **84% 이상 제거**했음을 시사한다. 비록 이것이 즉각적인 예측 정확도(DA)의 획기적 개선으로 이어지지는 않았으나, 모델의 거동(Behavior)이 '추종(Lagging)'에서 '독립적 판단(Independent Inference)'으로 전환되었다는 점에서 중요한 공학적 성과이다.

4.3 통계적 가설 검정 (Statistical Hypothesis Test)

뉴스 데이터가 주가 변동에 선행하는 인과관계가 있는지 확인하기 위해 그래인저 인과관계 검정(Granger Causality Test)을 수행하였다. 검정 결과, Lag 1에서의 F-통계량은 **0.7327**, p-value 는 **0.3959**로 나타났다.

이는 유의수준 0.05를 크게 상회하는 수치로, 귀무가설("뉴스는 주가 예측에 영향을 주지 않는다")을 기각할 수 없음을 의미한다. 즉, 본 연구에서 사용한 뉴스 심리 데이터는 애플(AAPL)과 같은 초효율적 시장의 무작위성을 통계적으로 설명하기에는 부족하였으며, 이는 **효율적 시장 가설(EMH)**이 현대 주식 시장에서 **실효적으로 작동하고 있음**을 재확인하는 결과이다.

V. 결론 및 한계점 (Conclusion & Limitations)

본 연구는 금융 시계열 데이터의 고질적 난제인 '지속성 함정(Persistence Trap)'을 극복하기 위해, 병렬 연산이 가능한 트랜스포머(Transformer) 아키텍처와 LLM 기반의 뉴스 심리 분석을 결합한 멀티 모달(Multi-modal) 모델을 제안하였다. 애플(AAPL) 주가를 대상으로 수행한 실험 결과와 이에 따른 연구의 한계 및 향후 발전 방향은 다음과 같다.

첫째, 효율적 시장 가설(EMH)의 강력한 유효성을 재확인하였다. 과거 가격 데이터만을 학습한 Baseline 모델은 49.79%의 정확도를 기록하며 '랜덤 워크(Random Walk)' 이론을 실증하였고, 뉴스 데이터를 결합한 제안 모델 역시 50.40%를 기록하여 통계적으로 유의미한 초과 성과를 달성하지 못했다. 이는 고도화된 딥러닝 기술이라 할지라도, 이미 공개된 정보(Past Prices & Public News)만으로는 초효율적 시장의 무작위성을 완전히 극복하기 어렵다는 경제학적 장벽을 시사한다.

둘째, '정보 반응성(Responsiveness)' 개선을 통한 공학적 가치를 발견하였다. 비록 수익성 측면에서는 시장을 이기지 못했으나, 정성적 분석 결과 뉴스 데이터가 모델의 **반응 시차(Lag)를 단축시키는 트리거(Trigger)** 역할을 수행함을 확인하였다. Baseline 모델이 전일 종가를 단순히 복제하는 '직렬 의존성(Serial Dependence)'을 보인 반면, 제안 모델은 외부 뉴스 충격에 반응하여 독립적인 예측 패턴을 형성하려는 구조적 변화를 보였다. 이는 AI가 시장의 반응 속도를 기술적으로 보정할 수 있다는 중요한 공학적 가능성을 제시한다.

본 연구는 이러한 성과에도 불구하고 다음과 같은 한계를 가지며, 이를 보완하기 위한 후속 연구를 제안한다.

1. **데이터의 구조적 한계 (Market Efficiency):** 본 연구의 대상인 애플(AAPL)은 전 세계에서 가장 효율적인 시장으로, 정보 비대칭이 거의 존재하지 않는다. 따라서 뉴스가 공시되는 즉시 가격에 반영되므로 예측의 '엣지(Edge)'를 찾기 어렵다. 향후 연구에서는 정보 소외가 발생하거나 비효율성이 존재하는 **중소형주(Small-cap) 및 신흥국 시장**을 대상으로 한다면, 뉴스 데이터의 선행적 가치가 더 크게 발휘될 것으로 기대된다.
2. **뉴스 분석의 깊이 (Causal Inference):** 현재의 모델은 뉴스의 긍/부정(Sentiment Score)을 -1.0 에서 +1.0 으로 단순 정량화하여 복잡한 거시경제 맥락을 담는 데 한계가 있었다. 향후에는 단순 감성 분석을 넘어, 뉴스 이벤트 간의 인과관계(Causal Inference)를 추론하거나 '실적 발표', '금리 인상' 등 특정 이벤트에 가중치를 부여하는 고차원적인 모델링이 필요하다.

결론적으로 본 연구는 "단순한 딥러닝 기술의 적용만으로는 효율적 시장의 무작위성을 이길 수 없다"는 사실을 엄밀하게 검증하였다. 그러나 동시에, 뉴스 심리 데이터가 시계열 모델의 구조적 결함인 '시차'를 완화하는 핵심 변수임을 규명함으로써, 향후 금융 AI 연구가 단순한 수치 예측을 넘어 *시장의 효율성 검증 및 보정 도구'로서 발전할 수 있는 토대를 마련하였다.

[참고문헌]

1. Thomas Fischer and Christopher Krauss, Deep learning with long short-term memory networks for financial market predictions, European Journal of Operational Research, 270, 2, 654-669, 2018.
2. Eugene F. Fama, Efficient Capital Markets: A Review of Theory and Empirical Work, The Journal of Finance, 25, 2, 383-417, 1970.
3. Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser and Illia Polosukhin, Attention Is All You Need, Advances in Neural Information Processing Systems, 30, 5998-6008, 2017.
4. Clive W. J. Granger, Investigating Causal Relations by Econometric Models and Cross-spectral Methods, Econometrica, 37, 3, 424-438, 1969.
5. Google Team, Gemini: A Family of Highly Capable Multimodal Models, Google DeepMind, 2024, <https://deepmind.google/technologies/gemini/>, 2025.10.
6. Diederik P. Kingma and Jimmy Ba, Adam: A Method for Stochastic Optimization, International Conference on Learning Representations (ICLR), 2015.